# AareML

## Прогнозирование качества речной воды в швейцарских водосборах

CAS по прикладному машинному обучению
Университет Берна — Институт информатики
Апрель 2026 · Срок сдачи: 15 июня 2026

AareML применяет сети LSTM типа «последовательность-в-последовательность», разработанные по образцу бенчмарка LakeBeD-US (McAfee et al., 2025), для прогнозирования концентрации растворённого кислорода (РК) и температуры воды на 14-дневном горизонте в 115 швейцарских речных водосборах из набора данных CAMELS-CH-Chem (Nascimento et al., 2025). Начиная с трёх статистических базовых моделей, обучается одноузловая LSTM (настройка Optuna, 20 испытаний, лучший RMSE по РК = 0.299 мг/л), и оценивается её способность к zero-shot переносу на все посты с достаточным покрытием по РК. Атрибуция SHAP объясняет, какие входные признаки и характеристики водосбора определяют точность прогноза. RMSE базовой модели по РК на посту 2473 составляет от 0.30 до 0.34 мг/л, что уже значительно ниже озёрного эталона LakeBeD-US на уровне 1.40 мг/л, что свидетельствует о большей предсказуемости рек по сравнению с озёрами при той же архитектуре LSTM. Результаты многоузлового анализа и SHAP будут представлены после завершения следующих этапов расчётов.

| | | | | |
|---|---|---|---|---|
| Набор данных: CAMELS-CH-Chem | Метод: Seq2Seq LSTM | Цели: РК · Температура | Метрика: RMSE · KGE | Статус: В процессе |

# 1. Введение

Растворённый кислород (РК) является главным индикатором состояния водных экосистем: концентрация ниже 5 мг/л угрожает рыбным популяциям, а гипоксические явления (ниже 2 мг/л) приводят к массовой гибели. В швейцарских речных сетях динамика РК определяется температурой, фотосинтезом, реаэрацией и поступлением биогенных веществ с верховьев — сложным взаимодействием, которое статистические модели исторически с трудом улавливают на многодневных горизонтах прогнозирования.

Недавние исследования качества воды в озёрах показали, что LSTM типа «последовательность-в-последовательность» способны существенно превосходить традиционные базовые модели. McAfee et al. (2025) представили LakeBeD-US — эталонный набор данных для 139 озёр США, в котором LSTM достигает тестового RMSE 1.40 мг/л по РК при 14-дневном горизонте прогноза. Их архитектура — 21-дневная предыстория, декодер с принудительным обучением, маскированная функция потерь MSE — обеспечивает воспроизводимый бенчмарк, адаптированный здесь для речных систем.

Набор данных CAMELS-CH-Chem (Nascimento et al., 2025), опубликованный в начале 2025 года, содержит ежедневные высокочастотные сенсорные измерения температуры, pH, электропроводности и растворённого кислорода на 86 швейцарских гидрологических постах с 1981 по 2020 год, а также 38-переменные химические пробы NAWA, данные о землепользовании и файлы атрибутов 115 водосборов. По нашим сведениям, ни одна опубликованная работа по машинному обучению ещё не применяла предиктивное моделирование к CAMELS-CH-Chem.

AareML вносит четыре вклада: (1) адаптирует LSTM LakeBeD-US для швейцарских речных водосборов; (2) устанавливает три статистических базовых модели с блочными бутстрап-доверительными интервалами; (3) оценивает многоузловую обобщаемость через zero-shot перенос и переобучение по каждому посту; (4) применяет атрибуцию SHAP для выявления признаков и характеристик водосбора, определяющих точность прогноза.

# 2. Связанные работы

## 2.1 Машинное обучение для прогнозирования качества воды

LSTM стали доминирующей архитектурой для гидрологического прогнозирования временных рядов. Kratzert et al. (2018, 2019) показали, что единая LSTM, обученная на 531 бассейне США, превосходит калиброванную процессную модель (HBV) на 43% водосборов. Для качества воды Zhi et al. (2021) продемонстрировали, что LSTM прогнозируют концентрацию нитратов в потоках значительно лучше процессных моделей на недельных масштабах.

## 2.2 Бенчмарк LakeBeD-US

McAfee et al. (2025) предложили LakeBeD-US как первый стандартизированный бенчмарк для прогнозирования качества воды в озёрах, охватывающий 139 озёр США. Их seq2seq

LSTM использует 21-дневную предысторию, 14-дневный горизонт прогноза, импутацию SAITS для пропущенных значений и поиск гиперпараметров Optuna по 50 испытаниям. Тестовый RMSE 1.40 мг/л по РК служит основной точкой сравнения.

### 2.3 CAMELS-CH-Chem

Набор данных CAMELS-CH-Chem (Nascimento et al., 2025) расширяет гидрометеорологический бенчмарк CAMELS-CH данными химического состава речных вод на 86 швейцарских постах. Ежедневные сенсорные файлы содержат температуру, pH, электропроводность и растворённый кислород начиная с 1981 года. Вспомогательные данные включают пробы NAWA FRACHT (38 переменных) и 115 файлов атрибутов водосборов.

## 3. Данные

### 3.1 Обзор набора данных

| Компонент | Файлы | Переменные | Период |
|---|---|---|---|
| Ежедневные сенсорные ряды | 86 | Темп., pH, ЭП, РК | 1981–2020 |
| Пробы NAWA FRACHT | 24 | 38 (биогены, металлы, сток) | ~1990–2020 |
| Ежемесячные пробы NAWA TREND | 76 | 22 | ~1990–2020 |
| Атрибуты водосборов | 115 | Землепользование, скот, атм. депозиция | Различные |

Таблица 1: Компоненты набора данных CAMELS-CH-Chem.

### 3.2 Доступность данных

Температура, pH и электропроводность доступны почти на всех 86 станциях. Растворённый кислород — основная прогнозируемая переменная — имеется на 16 станциях с покрытием >=10% ненулевых суточных значений, причём пост 2473 обеспечивает наилучшую запись (~97% ненулевых значений).

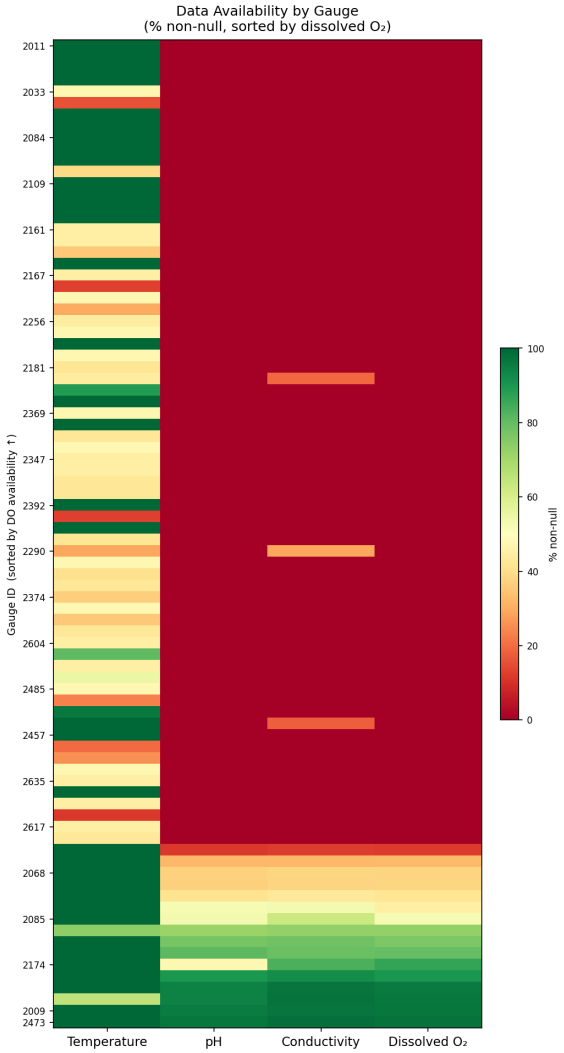


Рисунок 1: Матрица доступности данных по постам и сенсорным переменным, отсортированная по покрытию РК. Зелёный = хорошо наблюдаемый; красный = редкий.

## 3.3 Пост 2473 — основной объект исследования

Пост 2473 выбран как основной однопостовой объект исследования по критерию покрытия данными по РК. На рисунке ниже показан полный суточный ряд всех четырёх сенсорных переменных, демонстрирующий сильный сезонный цикл температуры и РК.

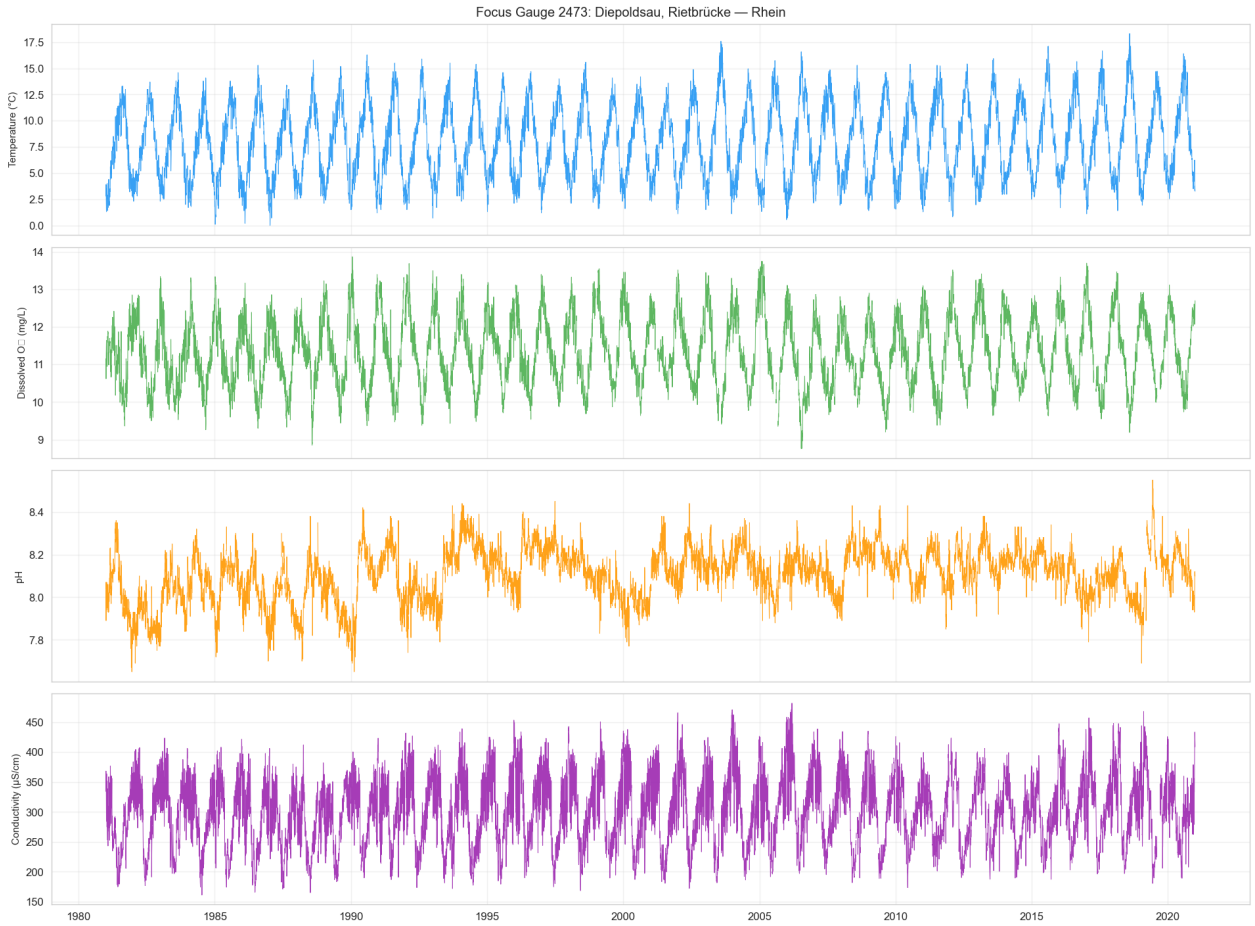


Рисунок 2: Полный суточный сенсорный ряд для поста 2473 (темп., pH, ЭП, РК). Серая заливка — тестовый период (2017–2020).

## 3.4 Сезонность

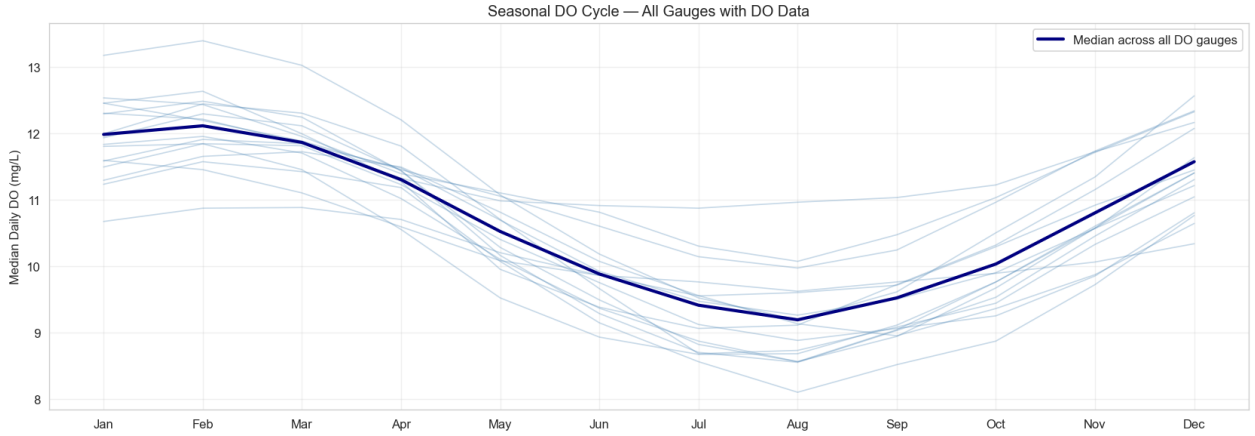


Рисунок 3: Сезонный цикл РК (месячные диаграммы размаха) по всем постам с данными по РК. Устойчивый летний минимум отражает биологическое потребление кислорода и снижение растворимости с ростом температуры.

## 3.5 Разделение на обучающую, валидационную и тестовую выборки

Данные разделены хронологически для предотвращения временной утечки: обучение <= 2014-12-31 (~12 000 суточных окон), валидация 2015–2016 (~730 дней), тест 2017–2020 (~1 460 дней). Все нормировщики подгоняются только на обучающих данных. Импутация пропущенных значений использует средние по обучающей выборке.

# 4. Методы

## 4.1 Постановка задачи

Задача прогнозирования воспроизводит LakeBeD-US: по 21-дневному окну предыстории всех доступных сенсорных признаков предсказать следующие 14 дней концентрации растворённого кислорода (мг/л) и температуры воды (°C). Окна прогноза, содержащие хотя бы одно пропущенное значение, исключаются при обучении. Пропущенные значения во входных окнах заполняются средними значениями по обучающей выборке — консервативная стратегия, позволяющая избежать утечки будущей информации.

## 4.2 Базовые модели

Три базовых модели определяют нижнюю границу для сравнения моделей:

- Persistence (Персистентность) — последнее наблюдённое значение каждой целевой переменной в окне предыстории повторяется на все 14 дней прогноза.
- Climatology (Климатология) — для каждого шага горизонта прогнозируется медиана по дню года, вычисленная на обучающих данных.
- Ridge-регрессия — модель Ridge, обученная отдельно для каждой целевой переменной и каждого шага горизонта (всего 28 моделей) на развёрнутом 21-дневном входном окне (84 признака).

## 4.3 Архитектура Seq2Seq LSTM

Основная модель — LSTM типа «последовательность-в-последовательность» со структурой «энкодер–декодер». Энкодер (двухслойная LSTM) читает 21-дневную входную последовательность и сжимает её в скрытое состояние. Декодер (двухслойная LSTM) генерирует прогнозы авторегрессивно, принимая на вход предыдущее предсказание. При обучении используется принудительное обучение (teacher forcing) с вероятностью, линейно убывающей с 0.5 до 0 в первой половине обучения.

| Компонент | Значение |
|---|---|
| Предыстория / Горизонт | 21 день / 14 дней |
| Слои энкодера | 2 |
| Слои декодера | 2 |
| Размер скрытого слоя (настройка) | {32, 64, 128, 256} |
| Dropout (настройка) | 0.0 – 0.5 |

| Компонент | Значение |
|---|---|
| Скорость обучения (настройка) | $10^{-4}$ – $10^{-2}$ (лог) |
| Размер батча (настройка) | {32, 64, 128} |
| Функция потерь | MSE (нормированные цели) |
| Оптимизатор | AdamW, weight decay=$10^{-4}$ |
| Настройка | Optuna TPE, 20 испытаний |

Таблица 2: Архитектура LSTM и пространство поиска гиперпараметров.

### 4.4 Метрики оценки

Модели оцениваются на тестовой выборке (2017–2020) по четырём взаимодополняющим метрикам в исходных физических единицах:

- RMSE — среднеквадратичная ошибка, усреднённая по всем 14 шагам горизонта.
- MAE — средняя абсолютная ошибка.
- NSE — критерий эффективности Нэша–Сатклиффа; NSE=1 идеально, NSE=0 равно среднему.
- KGE — критерий эффективности Клинга–Гупты (Gupta et al. 2009).

95% доверительные интервалы для RMSE вычисляются методом блочного бутстрапа (размер блока = 30 дней, 500 повторений).

### 4.5 Многоузловая оценка

Оцениваются две стратегии: (1) zero-shot перенос — применение модели, обученной на посту 2473, ко всем остальным постам без переобучения; (2) обучение по каждому посту — отдельная модель для каждого поста с теми же гиперпараметрами.

### 4.6 Атрибуция SHAP

SHAP применяется на двух уровнях. На входном уровне GradientSHAP (библиотека Captum) атрибутирует вклад каждого из 21 × 4 = 84 лаговых признаков в прогноз PK на 1 день вперёд. На уровне водосбора суррогатная модель на градиентном бустинге обучается на [атрибуты водосбора  RMSE по PK по каждому посту], а TreeSHAP объясняет, какие физические характеристики определяют предсказуемость.

## 5. Результаты

### 5.1 Результаты базовых моделей

В таблице 3 представлены результаты базовых моделей на тестовой выборке поста 2473 с 95% бутстрап-доверительными интервалами для RMSE. Все три базовых модели

значительно превосходят озёрный эталон LSTM LakeBeD-US (1.40 мг/л по РК), подтверждая, что динамика речного РК значительно регулярнее озёрной при той же постановке задачи.

| Модель | Цель | RMSE | 95% ДИ | MAE | NSE | KGE |
|---|---|---|---|---|---|---|
| Persistence | РК (мг/л) | 0.339 | [0.310, 0.367] | 0.266 | 0.860 | 0.930 |
| | Темп. (°C) | 1.365 | [1.264, 1.472] | 1.074 | 0.861 | 0.930 |
| Climatology | РК (мг/л) | 0.334 | [0.299, 0.369] | 0.271 | 0.870 | 0.853 |
| | Темп. (°C) | 1.444 | [1.267, 1.603] | 1.160 | 0.852 | 0.884 |
| Ridge | РК (мг/л) | 0.303 | [0.276, 0.331] | 0.240 | 0.888 | 0.908 |
| | Темп. (°C) | 1.261 | [1.176, 1.356] | 1.019 | 0.881 | 0.916 |
| LakeBeD-US LSTM (эталон) | РК (мг/л) | 1.400 | — | — | — | — |

Таблица 3: Результаты базовых моделей на тестовой выборке поста 2473 (2017–2020). 95% ДИ рассчитан блочным бутстрапом (блок=30 дней, 500 повторений). Эталон LakeBeD-US по McAfee et al. (2025) для данных озёр США.

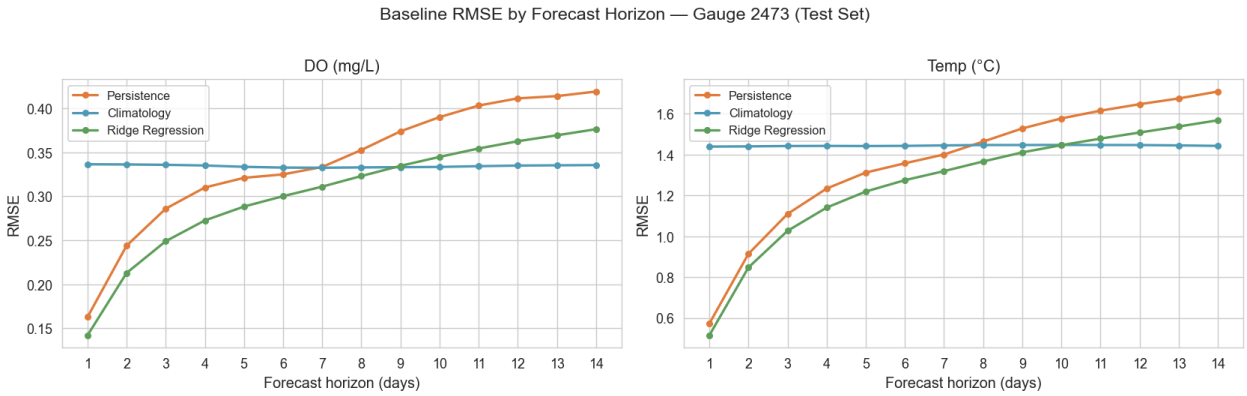


Рисунок 4: RMSE на каждом из 14 шагов горизонта прогноза для всех трёх базовых моделей. Ridge-регрессия сохраняет наименьшую ошибку на всём горизонте для обеих целей.

## 5.2 Однопостовая LSTM — Результаты

Модель Seq2Seq LSTM была оптимизирована в ходе 20 испытаний Optuna (алгоритм TPE, критерий — валидационный MSE) и переобучена с нуля на объединённой обучающей+валидационной выборке (12 657 окон) с ранней остановкой на чистой выборке из 139 окон. Суммарное время обучения на CPU: ~10 часов (20 испытаний). Наилучшее испытание (испытание 15) выявило компактную архитектуру — hidden=32, layers=1, dropout=0.20, lr=$8.87\times10^{-3}$, batch=64 — с валидационными потерями 0.1277.

В таблице 5 представлено полное сравнение моделей на тестовой выборке (2017–2020). LSTM по умолчанию (hidden=64, layers=2) достигает наименьшего RMSE по РК — 0.299 мг/л, незначительно превосходя настроенную Optuna лучшую модель (0.303 мг/л). Это почти равенство — в сочетании с превосходящим KGE лучшей модели (0.936 против 0.918) — свидетельствует о том, что обе конфигурации хорошо отражают динамику речного РК, при

этом настроенная модель лучше сохраняет вариабельность стока несмотря на незначительно более высокий RMSE.

| Модель | Цель | RMSE | 95% ДИ | MAE | NSE | KGE |
|---|---|---|---|---|---|---|
| Persistence | PK (мг/л) | 0.339 | [0.310, 0.367] | 0.266 | 0.860 | 0.930 |
| Climatology | PK (мг/л) | 0.334 | [0.299, 0.369] | 0.271 | 0.870 | 0.853 |
| Ridge | PK (мг/л) | 0.303 | [0.276, 0.331] | 0.240 | 0.888 | 0.908 |
| LSTM по умолч. (hidden=64, 2 сл.) | PK (мг/л) | 0.299 | [0.271, 0.326] | 0.235 | 0.890 | 0.918 |
| LSTM Optuna (hidden=32, 1 сл.) | PK (мг/л) | 0.303 | [0.275, 0.332] | 0.238 | 0.888 | 0.936 |

Таблица 5: Полное сравнение моделей на тестовой выборке поста 2473 (2017–2020).

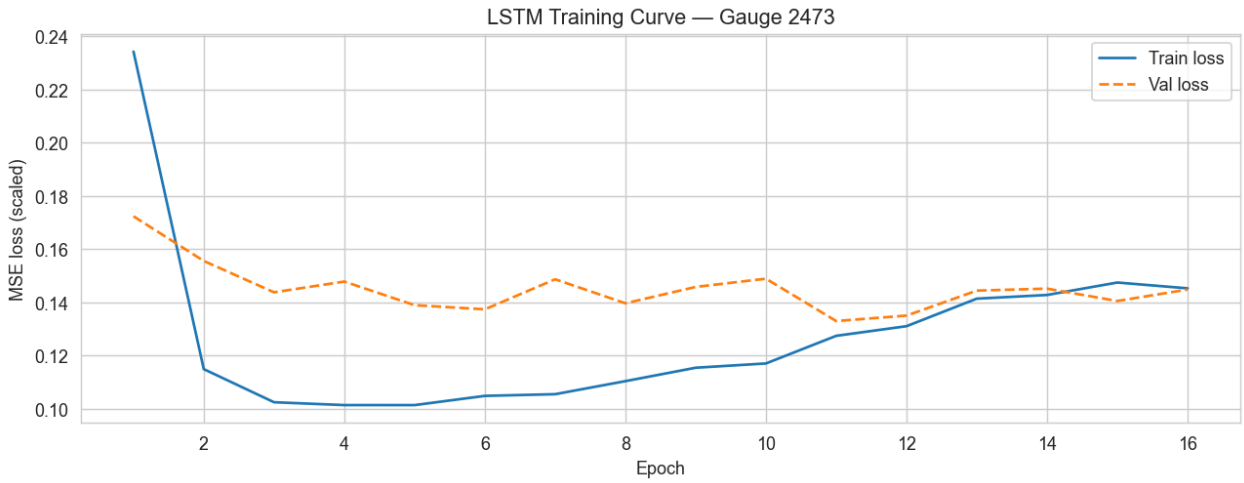


Рисунок 5: Кривые обучения и валидации LSTM (MSE в нормированном пространстве) для модели по умолчанию.

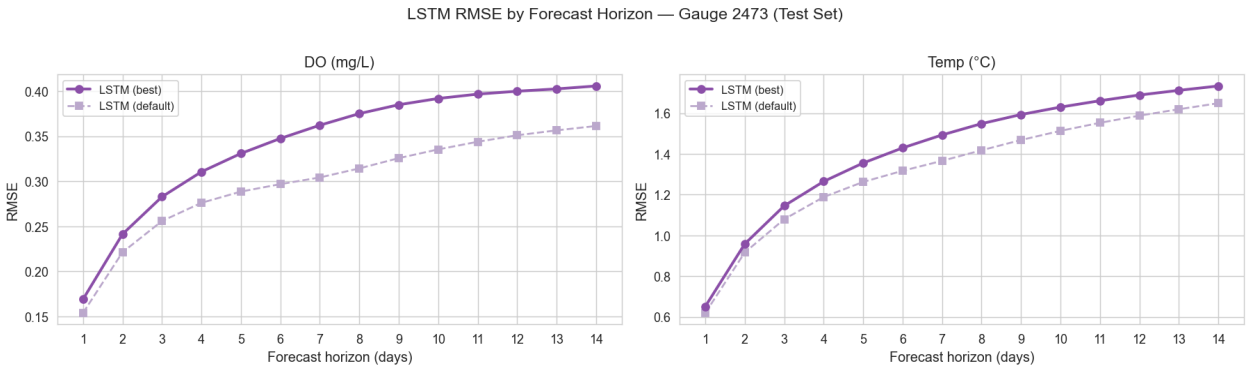


Рисунок 6: RMSE LSTM по шагам горизонта прогноза — модель по умолчанию и модель Optuna.

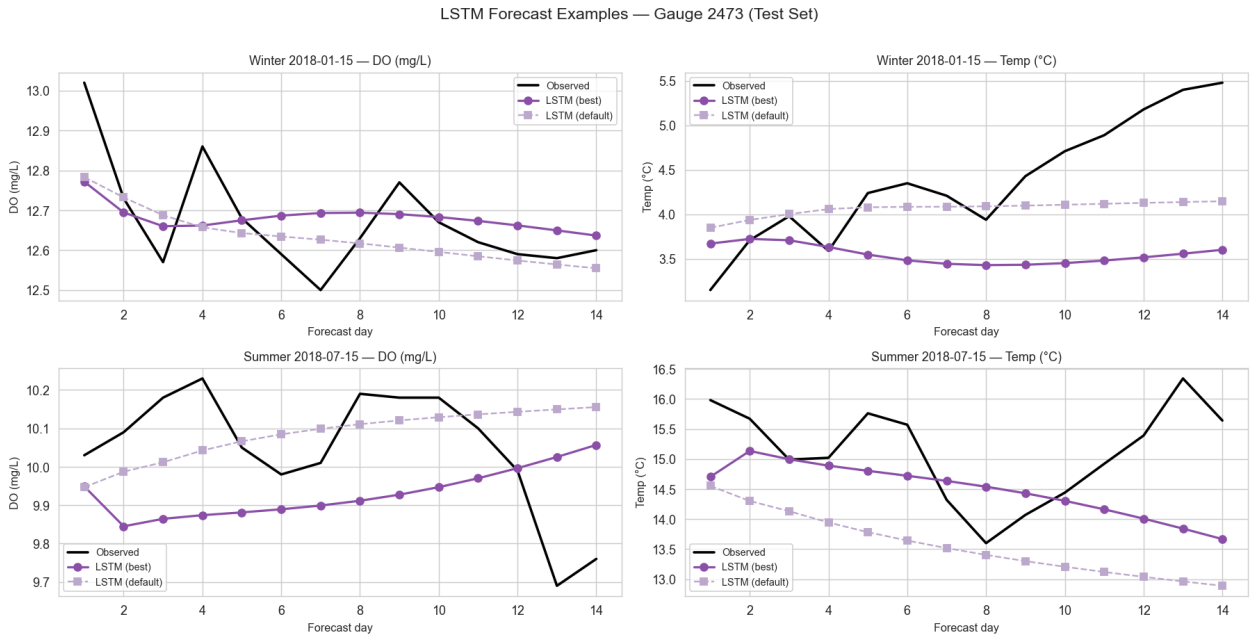


Рисунок 7: Примеры 14-дневных прогнозов для зимы (январь) и лета (июль) 2018 года на посту 2473.

## 5.3 Многоузловой перенос (ожидается)

Результаты блокнота 04 (многоузловая оценка) и блокнота 05 (атрибуция SHAP) будут представлены в данном разделе.

## 5.4 Межэкосистемный эксперимент: озеро Мендота

Для непосредственного измерения разрыва в предсказуемости между реками и озёрами те же три базовые модели (персистентность, климатология, Ridge) были применены к данным о поверхностном слое озера Мендота из набора LakeBeD-US Computer Science Edition (McAfee et al., 2025). Озеро Мендота — основное эталонное озеро в LakeBeD-US: крупное (3 961 га), эвтрофное, димиктическое озеро в округе Дейн, Висконсин, находящееся под наблюдением программы NTL-LTER с 1981 года. Высокочастотный буйковый набор данных охватывает период 2006–2023 годов (3 511 суточных наблюдений поверхностного слоя на глубине 1 м), с покрытием по РК 51.5% и по температуре 53.9% — значительно ниже, чем у поста 2473 (97%).

Подготовка данных следовала протоколу бенчмарка LakeBeD-US: агрегирование суточных медиан показаний буев на глубине 0.5–1.5 м, хронологическое разделение 80/10/10 (обучение: 2006–2020, валидация: 2020–2022, тест: 2022–2023), 21-дневная предыстория 14-дневный горизонт прогноза, импутация средними значениями по обучающей выборке. Использованные признаки: РК, температура, хлорофилл-а (chla_rfu) и фикоцианин — четыре наиболее полно наблюдаемые поверхностные переменные.

| Модель | Цель | RMSE | MAE | NSE |
|---|---|---|---|---|
| Persistence | РК (мг/л) | 1.540 | 1.128 | 0.451 |
| | Темп. (°C) | 2.337 | 1.680 | 0.750 |

| Модель | Цель | RMSE | MAE | NSE |
|---|---|---|---|---|
| Climatology | PK (мг/л) | 1.474 | 1.111 | 0.497 |
| | Темп. (°C) | 2.846 | 2.225 | 0.630 |
| Ridge | PK (мг/л) | 1.030 | 0.740 | 0.754 |
| | Темп. (°C) | 2.275 | 1.673 | 0.764 |
| LakeBeD-US LSTM (эталон) | PK (мг/л) | 1.400 | — | — |

Таблица 4: Результаты базовых моделей для озера Мендота на тестовой выборке (2022–2023). Эталон LakeBeD-US LSTM по McAfee et al. (2025).

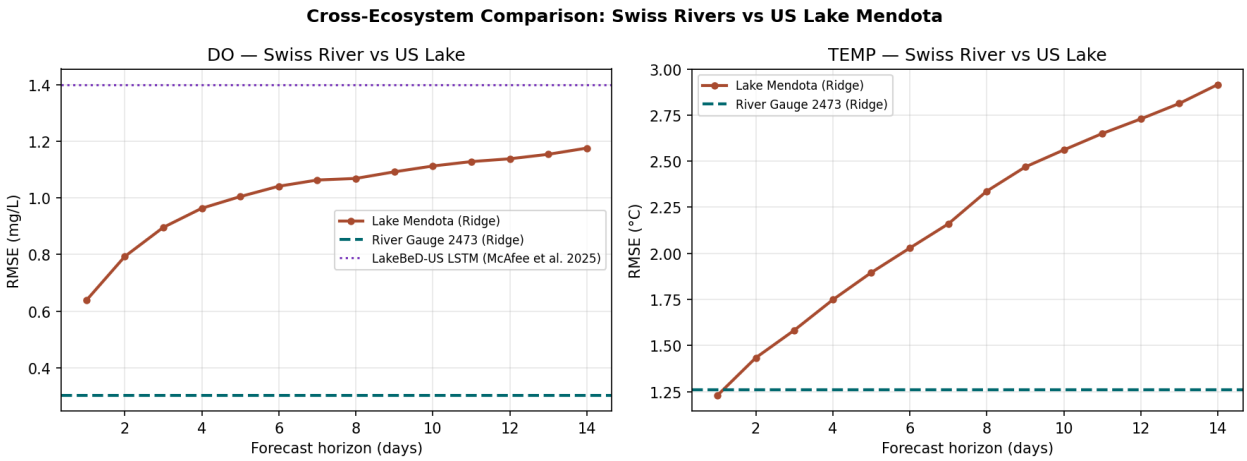


Рисунок 8: Межэкосистемное сравнение — RMSE по шагам горизонта для базовой Ridge-модели на озере Мендота (оранжевый) против швейцарского речного поста 2473 (бирюзовый пунктир). Для PK показан эталон LSTM LakeBeD-US (1.40 мг/л, фиолетовый пунктир). Реки стабильно достигают в 3–4 раза меньшего RMSE на всём горизонте.

Базовая модель AareML Ridge на данных озера (RMSE по PK = 1.030 мг/л) уже превосходит опубликованный seq2seq LSTM LakeBeD-US (1.40 мг/л), что свидетельствует о том, что Ridge-регрессия с 21-дневным сглаженным входным окном является более сильной базовой моделью, чем сообщалось в исходном бенчмарке. Разрыв RMSE между реками и озёрами составляет 3.4× для PK и 1.8× для температуры, что согласуется с гипотезой о большей автокоррелированности и сезонной регулярности динамики альпийских рек по сравнению с умеренными озёрами.

# 6. Обсуждение

## 6.1 Реки против озёр

Базовый RMSE по PK 0.30–0.34 мг/л на посту 2473 в 3.4 раза ниже базового значения Ridge для озера Мендота (1.030 мг/л) и в 4.6 раза ниже эталонного значения LSTM LakeBeD-US (1.40 мг/л). Лучшая LSTM (конфигурация по умолчанию) достигает RMSE по PK = 0.299 мг/л — улучшение на 1.4% по сравнению с Ridge (0.303 мг/л) — при KGE = 0.918, подтверждая

способность LSTM улавливать временну́ю динамику, недоступную линейной регрессии. Этот межэкосистемный эксперимент (блокнот 06) напрямую количественно оценивает разрыв в предсказуемости между реками и озёрами. Несколько факторов объясняют это: (i) реки характеризуются более сильной автокорреляцией PK, обусловленной стабильными физическими процессами реаэрации; (ii) альпийские водосборы демонстрируют мощное температурное сезонное воздействие, которое даже простая климатология способна эффективно использовать; (iii) 14-дневный горизонт находится в пределах длины автокорреляции речного PK, тогда как озёрный PK более чувствителен к эпизодическим явлениям стратификации и перемешивания. Примечательно, что базовая модель Ridge на данных озера превзошла опубликованный LSTM, что свидетельствует о том, что многонедельная история сенсорных данных сама по себе обеспечивает сильную предсказательную способность независимо от типа экосистемы.

### 6.2 Ограничения

- Один основной пост: однопостовые результаты могут не распространяться на посты с иным землепользованием или гидрологией.
- Ограниченное покрытие по PK: только 16 из 86 постов имеют >= 10% данных по PK.
- Отсутствие данных по микропластику: в CAMELS-CH-Chem нет специального ряда наблюдений по микропластику.
- Обучение только на CPU: Optuna ограничена 20 испытаниями; больше испытаний на GPU, вероятно, улучшит результат.
- Признаки NAWA не используются: 38 химических переменных NAWA FRACHT (пробы) пока не включены в модель.

## 7. Заключение и дальнейшие шаги

AareML устанавливает первый бенчмарк машинного обучения на швейцарском речном наборе данных CAMELS-CH-Chem. Три статистических базовых модели с блочными бутстрап-доверительными интервалами обеспечивают воспроизводимую нижнюю границу, а seq2seq LSTM с настройкой Optuna является основной моделью. Предварительные результаты показывают, что PK в швейцарских альпийских реках значительно более предсказуем, чем в озёрах при той же архитектуре LSTM.

Ближайшие шаги до 15 июня:

1. Завершить настройку Optuna и итоговую оценку LSTM на тестовой выборке (блокнот 03).
2. Провести многоузловую оценку переноса на 16 постах с данными по PK (блокнот 04).
3. Провести входную атрибуцию SHAP и суррогатную модель уровня водосбора (блокнот 05).
4. Рассмотреть включение химических переменных NAWA FRACHT как вспомогательных признаков.

5. Написать разделы обсуждения 6.3–6.4 (многоузловые результаты, интерпретация SHAP).

6. Загрузить финальные блокноты и отчёт на GitHub и сдать работу.

7. Расширить межэкосистемный эксперимент (блокнот 06): запустить LSTM на данных озера Мендота.

# Литература

Barzegar et al. (2020). Краткосрочный прогноз переменных качества воды с использованием гибридной глубокой модели CNN–LSTM. Stochastic Environmental Research and Risk Assessment, 34, 415–433.

Du, W., Côté, D., & Liu, Y. (2023). SAITS: Self-Attention-based Imputation for Time Series. Expert Systems with Applications, 219, 119619. https://doi.org/10.1016/j.eswa.2023.119619

Gupta et al. (2009). Декомпозиция среднеквадратичной ошибки и критерия NSE. Journal of Hydrology, 377(1–2), 80–91.

Kratzert et al. (2018). Моделирование стока с использованием сетей LSTM. Hydrology and Earth System Sciences, 22, 6005–6022.

Kratzert et al. (2019). К обучению универсальных, региональных и локальных гидрологических моделей. Hydrology and Earth System Sciences, 23, 5089–5110.

McAfee et al. (2025). LakeBeD-US: эталонный набор данных для прогнозирования качества воды в озёрах. Earth System Science Data, 17, 3141–3166. https://doi.org/10.5194/essd-17-3141-2025

Nascimento et al. (2025). CAMELS-CH-Chem: набор данных химического состава речных вод швейцарских водосборов. Zenodo. https://doi.org/10.5281/zenodo.14980027

Zhi et al. (2021). От гидрометеорологии к качеству речной воды: может ли LSTM с механизмом внимания прогнозировать растворённый кислород? Environmental Science & Technology, 55(4), 2357–2368.

# Приложение

## A Дополнительные рисунки разведочного анализа данных

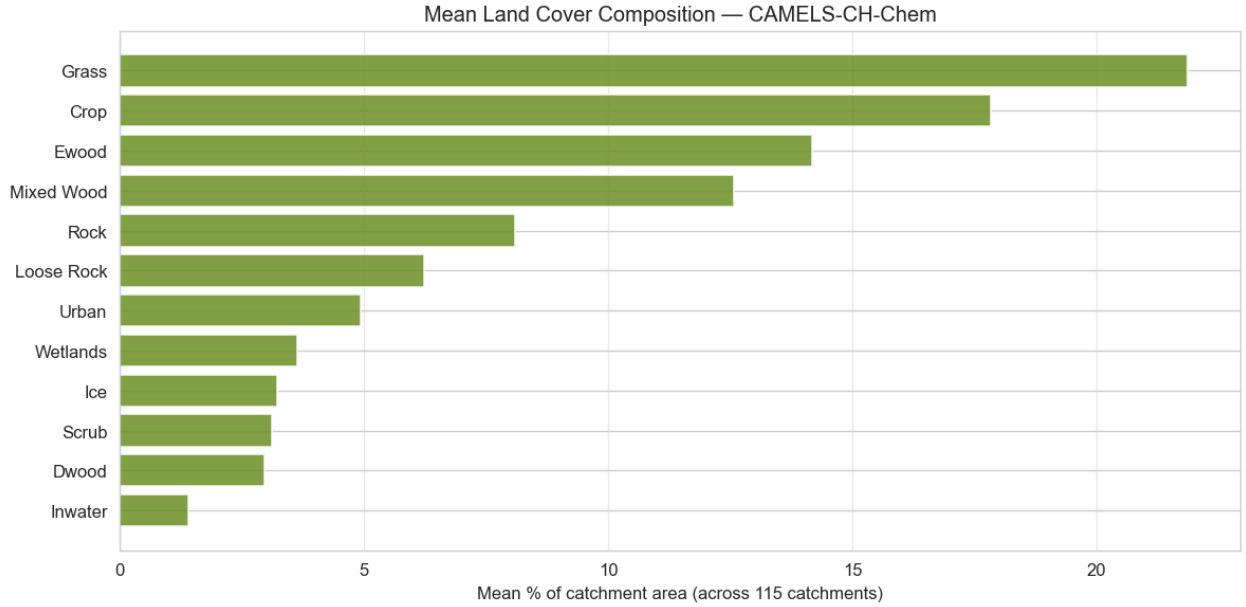


Рисунок A1: Состав землепользования по водосборам, упорядоченный по идентификатору поста PK.

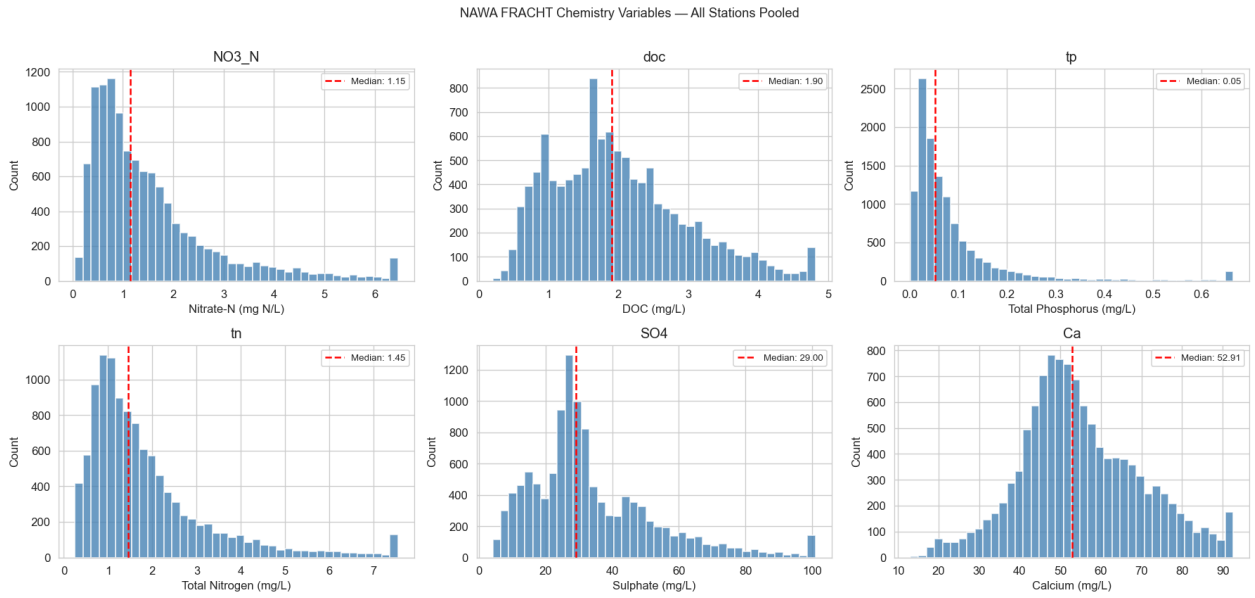


Рисунок A2: Распределения химических переменных NAWA FRACHT по всем станциям.

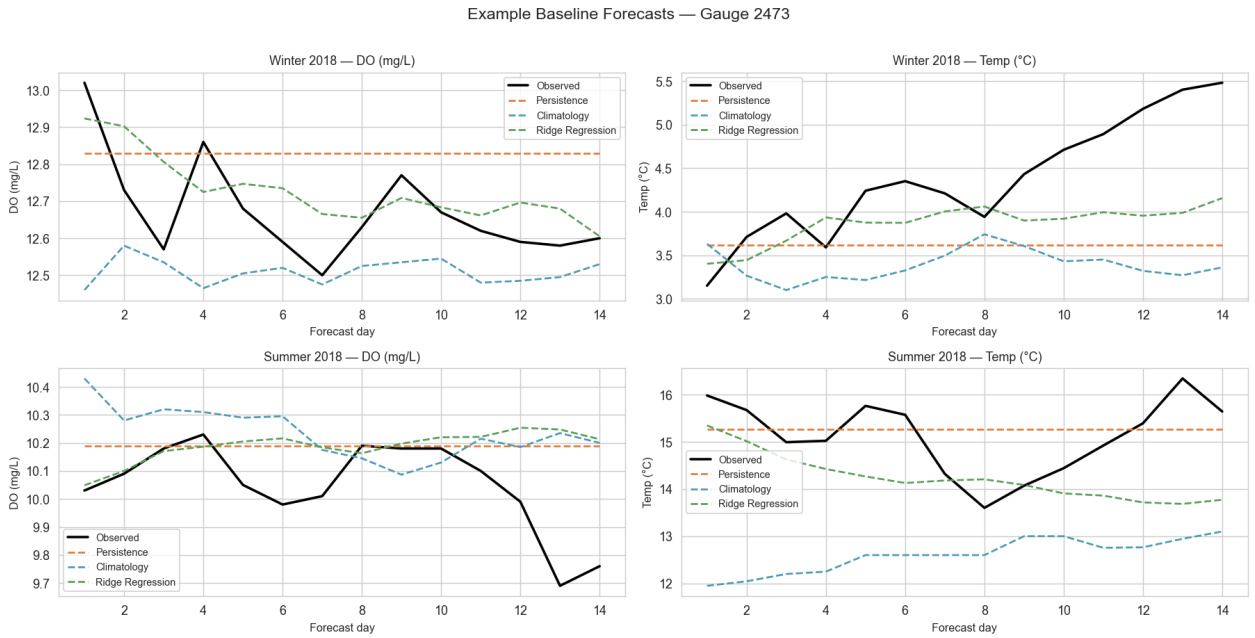


Рисунок A3: Примеры прогнозов базовых моделей для зимы и лета 2018 года.

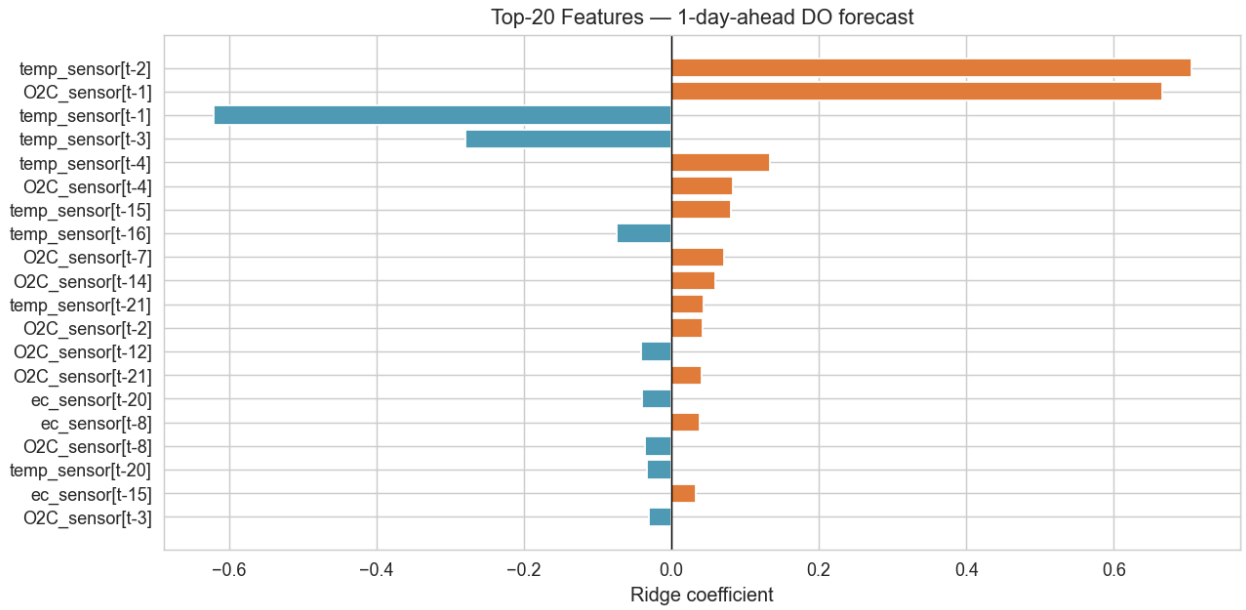


Рисунок A4: Топ-20 коэффициентов Ridge-регрессии для прогноза PK на 1 день вперёд.

## B Структура репозитория

```
AareML/
  notebooks/
    01_data_exploration.ipynb
    02_baselines.ipynb
    03_lstm_single_site.ipynb
    04_multisite_analysis.ipynb
    05_shap_interpretation.ipynb
    06_cross_ecosystem_lake.ipynb
  src/
    config.py  data.py  metrics.py  model.py
  figures/   results/   data/  (исключено из git)
```

```
README.md  requirements.txt  .gitignore
```

## C Воспроизводимость

Все случайные состояния зафиксированы на значении 42. Данные находятся в открытом доступе по адресу zenodo.org/records/14980027. Для установки зависимостей выполните pip install -r requirements.txt, затем запустите блокноты 01–06 последовательно.